

# PRML の 3 章のための数学

サイボウズ・ラボ 光成滋生

2011 年 4 月 26 日

## 1 概要

この文章は『パターン認識と機械学習』(以下 PRML) の 3 章を理解するために必要な数学をまとめてみたものです。間違い、質問などございましたら, herumi@nifty.com または twitterID:herumi までご連絡ください。

## 2 最小二乗法

### 2.1 微分の復習

$x, y$  を縦ベクトルとして

$$\frac{\partial}{\partial x}(x^T y) = y.$$

$$\frac{\partial}{\partial y}(x^T y) = x.$$

ここで  $\frac{\partial}{\partial x}$  は  $\frac{\partial}{\partial x_i}$  を縦に並べた縦ベクトルとする。2 章でも述べたが  $\frac{\partial}{\partial x}$  を  $\nabla$  と書くこともあるが PRML では場所によって縦ベクトル (3.22) だったり, 横ベクトル (3.13) だったりする。常に縦ベクトルとしたほうが混乱は少ない。

### 2.2 誤差関数の最小化

$$f(w) = \sum_{n=1}^N \{t_n - w^T \phi(x_n)\}^2 + \lambda w^T w$$

とする。ここで  $w$  と  $\phi(x_n)$  は  $M$  次元縦ベクトルである。

$$\Phi^T = (\phi(x_1) \cdots \phi(x_N))$$

とおく。  $\Phi$  は  $N$  行  $M$  列の行列である。  $f(w)$  を  $w$  で微分しよう。

$$\frac{\partial}{\partial w} f(w) = 2 \sum_{n=1}^N \{t_n - w^T \phi(x_n)\} (-\phi(x_n)) + 2\lambda w.$$

一般に縦ベクトル  $x, y$  に対して

$$(x^T y)y = (y^T x)y = y(y^T x) = (yy^T)x$$

だから  $t = (t_1, \dots, t_N)^T$  とおくと

$$\begin{aligned} \frac{1}{2} \frac{\partial}{\partial w} f(w) &= - \sum_n t_n \phi(x_n) + \sum_n (\phi(x_n) \phi(x_n)^T) w + \lambda w \\ &= -\Phi^T t + \Phi^T \Phi w + \lambda w \\ &= -\Phi^T t + (\Phi^T \Phi + \lambda I) w = 0. \end{aligned}$$

よって  $\det(\lambda I + \Phi^T \Phi) \neq 0$  のとき

$$w_{\text{ML}} = (\lambda I + \Phi^T \Phi)^{-1} \Phi^T t$$

が最尤解.  $y = \Phi w$  が予測値である.

## 2.3 正射影

前節で  $\lambda = 0$  のときを考える.

$$y = \Phi(\Phi^T \Phi)^{-1} \Phi^T t$$

となる. ここでこの式の幾何学的な解釈を考えてみよう.

$\Phi = (a_1 \cdots a_M)$  と縦ベクトルの集まりで表す.  $N - M$  個のベクトル  $b_1, \dots, b_{N-M}$  を追加して,  $\{a_1, \dots, a_M, b_1, \dots, b_{N-M}\}$  全体で  $N$  次元ベクトル空間の基底であるようにとる. その際  $b_i$  を  $a_j$  と直交するようにとれる.

$$a_i^T b_j = 0.$$

さて  $X = \Phi(\Phi^T \Phi)^{-1} \Phi^T$  とおくと,  $X\Phi = \Phi$ . これは  $Xa_i = a_i$  を意味する. つまり  $X$  は  $a_1, \dots, a_M$  で生成される部分空間  $V = \langle a_1, \dots, a_M \rangle$  の点を動かさない. また  $b_j$  のとりかたから  $Xb_j = 0$  も成り立つ. つまり  $X$  は部分空間  $\langle b_1, \dots, b_{N-M} \rangle$  の点を 0 につづす.

二つ合わせると,  $X$  は任意の点を部分空間  $V$  方向につづす写像, つまり  $V$  への正射影写像と解釈できる.

式で書くと任意の点  $t$  を  $t = \sum_i s_i a_i + \sum_i t_i b_j$  と表したとすると,

$$y = Xt = \sum_i s_i a_i$$

となる.  $t$  から  $y$  への変換を係数だけを使って書いてみると

$$X : (s_1, \dots, s_M, t_1, \dots, t_{N-M}) \rightarrow (s_1, \dots, s_M, 0, \dots, 0).$$

これを見ると正射影のニュアンスがより明確になる.

## 2.4 行列での微分

$x$  を  $n$  次元ベクトル,  $A$  を  $m$  行  $n$  列として  $y = Ax$  とおく.

$$f(A) = \|y\|^2 = (Ax)^T Ax$$

を  $A$  で微分してみよう.

$$(Ax)^T Ax = \sum_s (Ax)_s (Ax)_s = \sum_s \left( \sum_t a_{st} x_t \right) \left( \sum_u a_{su} x_u \right) = \sum_{s,t,u} x_t x_u a_{st} a_{su}.$$

よって

$$\begin{aligned} \frac{\partial}{\partial a_{ij}} f(A) &= \sum_{s,t,u} x_t x_u \left( \left( \frac{\partial}{\partial a_{ij}} a_{st} \right) a_{su} + a_{st} \frac{\partial}{\partial a_{ij}} a_{su} \right) \\ &= \sum_{s,t,u} x_t x_u (\delta_{is} \delta_{jt} a_{su} + a_{st} \delta_{is} \delta_{ju}) \\ &= \left( \sum_u x_j x_u a_{iu} \right) + \left( \sum_t x_t x_j a_{it} \right) \\ &= 2 \sum_u x_j x_u a_{iu} \\ &= 2x_j (Ax)_i \\ &= 2(Axx^T)_{ij}. \end{aligned}$$

よって

$$\frac{\partial}{\partial A} \|Ax\|^2 = 2Axx^T.$$

## 2.5 Woodbury の逆行列の公式

行列  $A, B, C, D$  について

$$(A + BD^{-1}C)^{-1} = A^{-1} - A^{-1}B(D + CA^{-1}B)^{-1}CA^{-1}$$

が成り立つ.

(証明)

$$\begin{aligned} A^{-1}B(D + CA^{-1}B)^{-1}CA^{-1} &= A^{-1}B((DB^{-1}A + C)A^{-1}B)^{-1}CA^{-1} \\ &= (DB^{-1}A + C)^{-1}CA^{-1} \\ &= (DB^{-1}(A + BD^{-1}C))^{-1}CA^{-1} \\ &= (A + BD^{-1}C)^{-1}BD^{-1}CA^{-1} \end{aligned}$$

よって

$$\begin{aligned} \text{左辺} &= (I - (A + BD^{-1}C)^{-1}BD^{-1}C)A^{-1} \\ &= (A + BD^{-1}C)^{-1}((A + BD^{-1}C) - BD^{-1}C)A^{-1} \\ &= \text{右辺}. \end{aligned}$$

特に,  $A$  が  $n$  次正方行列で  $B$  を  $n$  次縦ベクトル  $x$ ,  $C = x^T$ ,  $D$  を  $n$  次単位行列とすると

$$(A + xx^T)^{-1} = A^{-1} - \frac{(A^{-1}x)(x^T A^{-1})}{1 + x^T A^{-1}x} \quad (1)$$

が成り立つ.

## 2.6 正定値対称行列

$n$  次元実対称行列  $A$  はある直行列  $P$  を用いて常に対角化可能であった.

$$P^{-1}AP = \text{diag}(\lambda_1, \dots, \lambda_n).$$

全ての固有値が正であるとき  $A$  を正定値といい,  $A > 0$  とかく. 全ての固有値が正または 0 であるとき, 半正定値といい,  $A \geq 0$  とかく.

任意の実ベクトル  $x$  について  $y = Px$  とおくと  $x$  が  $\mathbb{R}^n$  の全ての点をとるとき  $y$  も全ての点を渡る.

$$x^T Ax = \sum_i \lambda_i y_i^2$$

なので  $A \geq 0$  ならば  $x^T Ax \geq 0$ .  $A > 0$  のときは等号が成り立つのは  $x = 0$  のときのみである.

逆に任意の  $x$  について  $x^T Ax \geq 0$  とすると,  $y$  として単位ベクトル  $e_i$  を考えれば  $\lambda_i \geq 0$ . つまり  $A \geq 0$ .  
更に等号は  $x = 0$  のときに限るためには  $\lambda_i > 0$ . つまり  $A > 0$  であることが分かる. まとめると

$$A \geq 0 \iff \lambda_i \geq 0 \text{ for } \forall i.$$

$$A > 0 \iff \lambda_i > 0 \text{ for } \forall i.$$

この同値性から  $A > 0$  のとき  $A^{-1} > 0$  も分かる. 定義から  $A > 0, B > 0$  なら  $A + B > 0$  も成り立つ.  
また実ベクトル  $v$  に対して  $A = vv^T$  とおくと,  $A$  は実対称であり, 任意の  $x$  に対して

$$x^T Ax = (v^T x)^2 \geq 0$$

なので  $A \geq 0$ .

## 2.7 予測分布の分散

$S_N^{-1} = S_0^{-1} + \beta \Phi_N^T \Phi_N$  としたときの予測分布の分散

$$\sigma_N^2 = \frac{1}{\beta} + \phi^T S_N \phi$$

を考える.  $\beta > 0$  であり,  $S_0$  は共分散行列なので実正定値であることに注意する. まず計画行列  $\Phi_N$  は  $N$  が一つ増える毎に 1 行増える.  $v_N$  (煩雑なので  $v$  と略記する) を  $M$  次元縦ベクトルとして

$$\Phi_{N+1}^T = (\Phi_N^T \ v)$$

としよう. すると

$$S_{N+1}^{-1} = S_0^{-1} + \beta(\Phi_N^T \Phi_N + vv^T) = S_N^{-1} + \beta vv^T.$$

行列  $\beta vv^T$  は正定値であり,  $S_N$  に関して帰納法を使うと全ての  $S_N$  は正定値であることが分かる.

公式 1 を使って

$$\begin{aligned} \sigma_{N+1}^2 &= \frac{1}{\beta} + \phi^T (S_N^{-1} + \beta vv^T)^{-1} \phi \\ &= \frac{1}{\beta} + \phi^T \left( S_N - \frac{(S_N v)(v^T S_N)}{1 + v^T S_N v} \right) \phi \\ &= \sigma_N^2 - z \end{aligned}$$

ここで  $S_N$  は対称なので

$$\begin{aligned} z &= \phi^T \frac{(S_N v)(v^T S_N)}{1 + v^T S_N v} \phi \\ &= \frac{1}{1 + v^T S_N v} (v^T S_N \phi)^2. \end{aligned}$$

$S_N$  は正定値なので任意の  $v$  に対して  $v^T S_N v \geq 0$ . よって  $z \geq 0$  となり

$$\sigma_{N+1}^2 \leq \sigma_N^2.$$

帰納法の流れを見ると,

$$\Phi_N^T = (v_1 \cdots v_N)$$

とおくと

$$S_N^{-1} = S_0^{-1} + \beta \sum_{i=1}^N v_i v_i^T$$

となることがわかる.  $v_i$  が基底関数のベクトルに訓練データの値を代入したものであることを考えると, 0 ベクトルになることは殆ど無い. また  $N \rightarrow \infty$  で 0 になるわけでもない. つまりそれらの和はどんどん大きくなる. そういう状況の元では  $\phi^T S_N \phi$  は 0 に近づき,

$$\sigma_N^2 \rightarrow \frac{1}{\beta}$$

となる.

## 2.8 カルバック距離

$p(x), q(x)$  を恒等的に 0 ではない確率密度関数とする. つまり  $p(x), q(x) \geq 0$ .

$$\text{KL}(p||q) = \int p(x) \log \frac{p(x)}{q(x)} dx$$

をカルバック距離 (Kullback-Leibler 距離, 相対エントロピー) という.

距離といいつつ,  $\text{KL}(p||q) = \text{KL}(q||p)$  とは限らないので距離の公理は満たさない. しかし,  $\text{KL}(p||q) \geq 0$  であり,  $\text{KL}(p||q) = 0 \iff p = q$  はいえる. これを示そう.

まず  $S(x) = e^{-x} + x - 1$  について  $S(x) \geq 0$  であり,  $S(x) = 0 \iff x = 0$  である.

なぜなら  $S'(x) = -e^{-x} + 1$ .  $S''(x) = e^{-x} \geq 0$  なので  $S'(x)$  は単調増加.  $S'(0) = 0$  より  $x > 0$  なら  $S'(x) > 0$ ,  $x < 0$  なら  $S'(x) < 0$ . つまり  $S(x)$  は 0 で最小値 0 をとる.

$$\int p(x) S(\log \frac{p(x)}{q(x)}) dx = \int p(x) (\frac{q(x)}{p(x)} + \log \frac{p(x)}{q(x)} - 1) dx = \text{KL}(p||q) + \int (q(x) - p(x)) dx = \text{KL}(p||q).$$

ここで  $p, q$  が確率密度関数なので  $\int p(x) dx = 1, \int q(x) dx = 1$  であることを使った.

この式の左辺の被積分関数は常に 0 以上. よって  $\text{KL}(p||q) \geq 0$ .

$\text{KL}(p||q) = 0$  ならば殆ど全ての  $x$  について

$$p(x) S(\log \frac{p(x)}{q(x)}) = 0.$$

$p = 0$  ではないので殆ど全ての  $x$  について

$$S(\log \frac{p(x)}{q(x)}) = 0.$$

$S(x) = 0$  となる  $x$  は 0 のときだけだから、殆ど全ての  $x$  について  $p(x) = q(x)$ .

真のモデル  $p(D|M)$  があったときに、モデルエビデンス  $p(D|M')$  とのカルバック距離  $\text{KL}(p(D|M)||p(D|M'))$  は 0 に近いほど真のモデルに近そうだということにする.

## 2.9 エビデンス関数の評価の式変形

$A = \alpha I + \beta \Phi^T \Phi$  とおくと

$$\begin{aligned} E(w) &= \frac{\beta}{2} \|t - \Phi w\|^2 + \frac{\alpha}{2} w^T w \\ &= \frac{1}{2} w^T (\alpha I + \beta \Phi^T \Phi) w - \beta t^T \Phi w + \frac{\beta}{2} \|t\|^2 \\ &= \frac{1}{2} w^T A w - \beta w^T \Phi^T t + \frac{\beta}{2} \|t\|^2. \end{aligned}$$

ここで一般に対称行列  $A$  とベクトル  $w, m$  について

$$\frac{1}{2} (w - m)^T A (w - m) = \frac{1}{2} w^T A w - w^T A m + \frac{1}{2} m^T A m.$$

この関数は  $w = m$  のとき最小値 0 をとる.

二つを比較することで  $E(w)$  は  $\beta \Phi^T t = A m$ , つまり

$$w = m_N = \beta A^{-1} \Phi^T t$$

のとき最小となる. 最小値は元の  $E(w)$  の式に  $w = m_N$  を代入すれば得られ,

$$E(m_N) = \frac{\beta}{2} \|t - \Phi m_N\|^2 + \frac{\alpha}{2} m_N^T m_N.$$

つまり

$$E(w) = \frac{1}{2} (w - m_N)^T A (w - m_N) + E(m_N)$$

と平方完成できる.

よって

$$\begin{aligned} E(w) &= \int \exp(-E(w)) dw \\ &= \exp(-E(m_N)) \int \exp(-\frac{1}{2} (w - m_N)^T A (w - m_N)) dw \\ &= \exp(-E(m_N)) (2\pi)^{M/2} |A|^{-1/2}. \end{aligned}$$

従って

$$\log p(\mathbf{t}|\alpha, \beta) = (N/2) \log\left(\frac{\beta}{2\pi}\right) + (M/2) \log\left(\frac{\alpha}{2\pi}\right) \log\left(\int \exp(-E(w)) dw\right) \quad (2)$$

$$= (M/2) \log \alpha + \frac{N}{2} \log \beta - E(m_N) - \frac{1}{2} \log |A| - \frac{N}{2} \log(2\pi). \quad (3)$$

## 2.10 ヘッセ行列

$x$  が  $n$  次縦ベクトルのとき,  $y = f(x)$  における 2 階微分の  $n$  次正方行列

$$H(f) = \left( \frac{\partial^2}{\partial x_i \partial x_j} f(x) \right)$$

をヘッセ行列という. 通常偏微分は可換なので, これは対称行列である.

1 階微分の行列 (ヤコビ行列) の行列式はその点の付近の拡大率を表していた. ヘッセ行列はその点の付近の関数の形を表す. たとえば正定値な場合は極小, 固有値が全て負の場合は極大, 固有値が正と負の両方の場合は鞍点となる.

$f = x^2 - y^2$ ,  $g = x^2 + y^2$  というグラフを見てみよう. 図 1 は原点で鞍点, 図 2 は原点で極小である. それぞれヘッセ行列は

$$H(f) = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix},$$

$$H(g) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$

となり, ヘッセ行列が原点での形に対応していることが分かる.




図 1  $f = x^2 - y^2$




図 2  $g = x^2 + y^2$

## 2.11 エビデンス関数の最大化の式変形

行列  $\beta\Phi^T\Phi$  をある行列  $P$  で対角化する.

$$P^{-1}(\beta\Phi^T\Phi)P = \text{diag}(\lambda_1, \dots, \lambda_M).$$

すると行列  $A = \alpha I + \beta\Phi^T\Phi$  も同じ  $P$  で対角化できて

$$P^{-1}AP = \text{diag}(\alpha + \lambda_1, \dots, \alpha + \lambda_M).$$

よって

$$|A| = \prod_{i=1}^M (\lambda_i + \alpha)$$

となる.  $\alpha$  で微分すると

$$\frac{\partial}{\partial \alpha} \log |A| = \sum_{i=1}^M \frac{1}{\lambda_i + \alpha}.$$

式 2 を  $\alpha$  で微分すると

$$\frac{\partial}{\partial \alpha} \log p(\mathbf{t}|\alpha, \beta) = \frac{M}{2\alpha} - \frac{1}{2} m_N^T m_N - \frac{1}{2} \sum \frac{1}{\lambda_i + \alpha} = 0.$$

よって

$$\alpha m_N^T m_N = M - \sum_{i=1}^M \frac{\alpha}{\lambda_i + \alpha} = \sum_{i=1}^M \frac{\lambda_i}{\lambda_i + \alpha}.$$

これを  $\gamma$  とおくと

$$\alpha = \frac{\gamma}{m_N^T m_N}.$$

$\beta$  についても同様にしてみる.  $\beta \Phi^T \Phi$  の固有値が  $\lambda_i$  だから  $\lambda_i$  は  $\beta$  に比例する. 比例係数は

$$\frac{\partial}{\partial \beta} \lambda_i = \frac{\lambda_i}{\beta}.$$

よって

$$\frac{\partial}{\partial \beta} \log |A| = \sum \frac{\lambda_i / \beta}{\lambda_i + \alpha} = \frac{\gamma}{\beta}.$$

式 2 を  $\beta$  で微分すると

$$\frac{N}{2\beta} - \frac{1}{2} \|\mathbf{t} - \Phi m_N\|^2 - \frac{\gamma}{2\beta} = 0.$$

よって

$$\frac{1}{\beta} = \frac{1}{N - \gamma} \|\mathbf{t} - \Phi m_N\|^2.$$