

PRML の 3 章のための数学

サイボウズ・ラボ 光成滋生

2011 年 4 月 22 日

1 概要

この文章は『パターン認識と機械学習』(以下 PRML) の 3 章を理解するために必要な数学をまとめてみたものです。

いくつかの定理は証明せずに認めますが, 可能な限り self-contained であることを目指してみました。概ね PRML に従っていますが, 違う方法をとっているところもあります。

間違い, 質問などございましたら, herumi@nifty.com または twitterID:herumi までご連絡ください。

2 最小二乗法

2.1 微分の復習

x, y を縦ベクトルとして

$$\frac{\partial}{\partial x}(x^T y) = y.$$

$$\frac{\partial}{\partial y}(x^T y) = x.$$

ここで $\frac{\partial}{\partial x}$ は $\frac{\partial}{\partial x_i}$ を縦に並べた縦ベクトルとする。2 章でも述べたが $\frac{\partial}{\partial x}$ を ∇ と書くこともあるが PRML では場所によって縦ベクトル (3.22) だったり, 横ベクトル (3.13) だったりする。常に縦ベクトルとしたほうが混乱は少ない。

2.2 誤差関数の最小化

$$f(w) = \sum_{n=1}^N \{t_n - w^T \phi(x_n)\}^2 + \lambda w^T w$$

とする。ここで w と $\phi(x_n)$ は M 次元縦ベクトルである。

$$\Phi^T = (\phi(x_1) \cdots \phi(x_N))$$

とおく。 Φ は N 行 M 列の行列である。 $f(w)$ を w で微分しよう。

$$\frac{\partial}{\partial \mathbf{w}} f(\mathbf{w}) = 2 \sum_{n=1}^N \{t_n - \mathbf{w}^T \phi(\mathbf{x}_n)\} (-\phi(\mathbf{x}_n)) + 2\lambda \mathbf{w}.$$

一般に縦ベクトル \mathbf{x} , \mathbf{y} に対して

$$(\mathbf{x}^T \mathbf{y}) \mathbf{y} = (\mathbf{y}^T \mathbf{x}) \mathbf{y} = \mathbf{y} (\mathbf{y}^T \mathbf{x}) = (\mathbf{y} \mathbf{y}^T) \mathbf{x}$$

だから $\mathbf{t} = (t_1, \dots, t_N)^T$ とおくと

$$\begin{aligned} \frac{1}{2} \frac{\partial}{\partial \mathbf{w}} f(\mathbf{w}) &= - \sum_n t_n \phi(\mathbf{x}_n) + \sum_n (\phi(\mathbf{x}_n) \phi(\mathbf{x}_n)^T) \mathbf{w} + \lambda \mathbf{w} \\ &= -\Phi^T \mathbf{t} + \Phi^T \Phi \mathbf{w} + \lambda \mathbf{w} \\ &= -\Phi^T \mathbf{t} + (\Phi^T \Phi + \lambda I) \mathbf{w} = 0. \end{aligned}$$

よって $\det(\lambda I + \Phi^T \Phi) \neq 0$ のとき

$$\mathbf{w}_{\text{ML}} = (\lambda I + \Phi^T \Phi)^{-1} \Phi^T \mathbf{t}$$

が最尤解. $\mathbf{y} = \Phi \mathbf{w}$ が予測値である.

2.3 正射影

前節で $\lambda = 0$ のときを考える.

$$\mathbf{y} = \Phi (\Phi^T \Phi)^{-1} \Phi^T \mathbf{t}$$

となる. ここでこの式の幾何学的な解釈を考えてみよう.

$\Phi = (a_1 \cdots a_M)$ と縦ベクトルの集まりで表す. $N - M$ 個のベクトル b_1, \dots, b_{N-M} を追加して, $\{a_1, \dots, a_M, b_1, \dots, b_{N-M}\}$ 全体で N 次元ベクトル空間の基底であるようにとる. その際 b_i を a_j と直交するようにとれる.

$$a_i^T b_j = 0.$$

さて $X = \Phi (\Phi^T \Phi)^{-1} \Phi^T$ とおくと, $X \Phi = \Phi$. これは $X a_i = a_i$ を意味する. つまり X は a_1, \dots, a_M で生成される部分空間 $V = \langle a_1, \dots, a_M \rangle$ の点を動かさない. また b_j のとりかたから $X b_j = 0$ も成り立つ. つまり X は部分空間 $\langle b_1, \dots, b_{N-M} \rangle$ の点を 0 につづす.

二つ合わせると, X は任意の点を部分空間 V 方向につづす写像, つまり V への正射影写像と解釈できる.

式で書くと任意の点 \mathbf{t} を $\mathbf{t} = \sum_i s_i a_i + \sum_i t_i b_j$ と表したとすると,

$$\mathbf{y} = X \mathbf{t} = \sum_i s_i a_i$$

となる. \mathbf{t} から \mathbf{y} への変換を係数だけを使って書いてみると

$$X : (s_1, \dots, s_N, t_1, \dots, t_{N-M}) \rightarrow (s_1, \dots, s_N, 0, \dots, 0).$$

これを見ると正射影のニュアンスがより明確になる.

2.4 行列での微分

x を n 次元ベクトル, A を m 行 n 列として $y = Ax$ とおく.

$$f(A) = \|y\|^2 = (Ax)^T Ax$$

を A で微分してみよう.

$$(Ax)^T Ax = \sum_s (Ax)_s (Ax)_s = \sum_s \left(\sum_t a_{st} x_t \right) \left(\sum_u a_{su} x_u \right) = \sum_{s,t,u} x_t x_u a_{st} a_{su}.$$

よって

$$\begin{aligned} \frac{\partial}{\partial a_{ij}} f(A) &= \sum_{s,t,u} x_t x_u \left(\left(\frac{\partial}{\partial a_{ij}} a_{st} \right) a_{su} + a_{st} \frac{\partial}{\partial a_{ij}} a_{su} \right) \\ &= \sum_{s,t,u} x_t x_u (\delta_{is} \delta_{jt} a_{su} + a_{st} \delta_{is} \delta_{ju}) \\ &= \left(\sum_u x_j x_u a_{iu} \right) + \left(\sum_t x_t x_j a_{it} \right) \\ &= 2 \sum_u x_j x_u a_{iu} \\ &= 2x_j (Ax)_i \\ &= 2(Axx^T)_{ij}. \end{aligned}$$

よって

$$\frac{\partial}{\partial A} \|Ax\|^2 = 2Axx^T.$$

2.5 Woodbury の逆行列の公式

行列 A, B, C, D について

$$(A + BD^{-1}C)^{-1} = A^{-1} - A^{-1}B(D + CA^{-1}B)^{-1}CA^{-1}$$

が成り立つ.

(証明)

$$\begin{aligned} A^{-1}B(D + CA^{-1}B)^{-1}CA^{-1} &= A^{-1}B((DB^{-1}A + C)A^{-1}B)^{-1}CA^{-1} \\ &= (DB^{-1}A + C)^{-1}CA^{-1} \\ &= (DB^{-1}(A + BD^{-1}C))^{-1}CA^{-1} \\ &= (A + BD^{-1}C)^{-1}BD^{-1}CA^{-1} \end{aligned}$$

よって

$$\begin{aligned} \text{左辺} &= (I - (A + BD^{-1}C)^{-1}BD^{-1}C)A^{-1} \\ &= (A + BD^{-1}C)^{-1}((A + BD^{-1}C) - BD^{-1}C)A^{-1} \\ &= \text{右辺}. \end{aligned}$$

特に, A が n 次正方行列で B を n 次縦ベクトル x , $C = x^T$, D を n 次単位行列とすると

$$(A + xx^T)^{-1} = A^{-1} - \frac{(A^{-1}x)(x^T A^{-1})}{1 + x^T A^{-1}x} \quad (1)$$

が成り立つ.

2.6 正定値対称行列

n 次元実対称行列 A はある直行列 P を用いて常に対角化可能であった.

$$P^{-1}AP = \text{diag}(\lambda_1, \dots, \lambda_n).$$

全ての固有値が正であるとき A を正定値といい, $A > 0$ とかく. 全ての固有値が正または 0 であるとき, 半正定値といい, $A \geq 0$ とかく.

任意の実ベクトル x について $y = Px$ とおくと x が \mathbb{R}^n の全ての点をとるとき y も全ての点を渡る.

$$x^T Ax = \sum_i \lambda_i y_i^2$$

なので $A \geq 0$ ならば $x^T Ax \geq 0$. $A > 0$ のときは等号が成り立つのは $x = 0$ のときのみである.

逆に任意の x について $x^T Ax \geq 0$ とすると, y として単位ベクトル e_i を考えれば $\lambda_i \geq 0$. つまり $A \geq 0$. 更に等号は $x = 0$ のときに限るためには $\lambda_i > 0$. つまり $A > 0$ であることが分かる. まとめると

$$A \geq 0 \iff \lambda_i \geq 0 \text{ for } \forall i.$$

$$A > 0 \iff \lambda_i > 0 \text{ for } \forall i.$$

この同値性から $A > 0$ のとき $A^{-1} > 0$ も分かる. 定義から $A > 0$, $B > 0$ なら $A + B > 0$ も成り立つ. また実ベクトル v に対して $A = vv^T$ とおくと, A は実対称であり, 任意の x に対して

$$x^T Ax = (v^T x)^2 \geq 0$$

なので $A \geq 0$.

2.7 予測分布の分散

$S_N^{-1} = S_0^{-1} + \beta \Phi_N^T \Phi_N$ としたときの予測分布の分散

$$\sigma_N^2 = \frac{1}{\beta} + \phi^T S_N \phi$$

を考える. $\beta > 0$ であり, S_0 は共分散行列なので実正定値であることに注意する. まず計画行列 Φ_N は N が一つ増える毎に 1 行増える. v_N (煩雑なので v と略記する) を M 次元縦ベクトルとして

$$\Phi_{N+1}^T = (\Phi_N^T v)$$

としよう. すると

$$S_{N+1}^{-1} = S_0^{-1} + \beta(\Phi_N^T \Phi_N + vv^T) = S_N^{-1} + \beta vv^T.$$

行列 βvv^T は正定値であり, S_N に関して帰納法を使うと全ての S_N は正定値であることが分かる.

公式 1 を使って

$$\begin{aligned}\sigma_{N+1}^2 &= \frac{1}{\beta} + \phi^T (S_N^{-1} + \beta v v^T)^{-1} \phi \\ &= \frac{1}{\beta} + \phi^T \left(S_N - \frac{(S_N v)(v^T S_N)}{1 + v^T S_N v} \right) \phi \\ &= \sigma_N^2 - z\end{aligned}$$

ここで S_N は対称なので

$$\begin{aligned}z &= \phi^T \frac{(S_N v)(v^T S_N)}{1 + v^T S_N v} \phi \\ &= \frac{1}{1 + v^T S_N v} (v^T S_N \phi)^2.\end{aligned}$$

S_N は正定値なので任意の v に対して $v^T S_N v \geq 0$. よって $z \geq 0$ となり

$$\sigma_{N+1}^2 \leq \sigma_N^2.$$

帰納法の流れを見ると,

$$\Phi_N^T = (v_1 \cdots v_N)$$

とおくと

$$S_N^{-1} = S_0^{-1} + \beta \sum_{i=1}^N v_i v_i^T$$

となることがわかる. v_i が基底関数のベクトルに訓練データの値を代入したものであることを考えると, 0 ベクトルになることは殆ど無い. また $N \rightarrow \infty$ で 0 になるわけでもない. つまりそれらの和はどんどん大きくなる. そういう状況の元では $\phi^T S_N \phi$ は 0 に近づき,

$$\sigma_N^2 \rightarrow \frac{1}{\beta}$$

となる.

2.8 カルバック距離

$p(x), q(x)$ を恒等的に 0 ではない確率密度関数とする. つまり $p(x), q(x) \geq 0$.

$$\text{KL}(p||q) = \int p(x) \log \frac{p(x)}{q(x)} dx$$

をカルバック距離 (Kullback-Leibler 距離, 相対エントロピー) という.

距離といいつつ, $\text{KL}(p||q) = \text{KL}(q||p)$ とは限らないので距離の公理は満たさない. しかし, $\text{KL}(p||q) \geq 0$ であり, $\text{KL}(p||q) = 0 \iff p = q$ はいえる. これを示そう.

まず $S(x) = e^{-x} + x - 1$ について $S(x) \geq 0$ であり, $S(x) = 0 \iff x = 0$ である.

なぜなら $S'(x) = -e^{-x} + 1$. $S''(x) = e^{-x} \geq 0$ なので $S'(x)$ は単調増加. $S'(0) = 0$ より $x > 0$ なら $S'(x) > 0$, $x < 0$ なら $S'(x) < 0$. つまり $S(x)$ は 0 で最小値 0 をとる.

$$\int p(x) S(\log \frac{p(x)}{q(x)}) dx = \int p(x) \left(\frac{q(x)}{p(x)} + \log \frac{p(x)}{q(x)} - 1 \right) dx = \text{KL}(p||q) + \int (q(x) - p(x)) dx = \text{KL}(p||q).$$

ここで p, q が確率密度関数なので $\int p(x) dx = 1, \int q(x) dx = 1$ であることを使った.

この式の左辺の被積分関数は常に 0 以上. よって $\text{KL}(p||q) \geq 0$.

$\text{KL}(p||q) = 0$ ならば殆ど全ての x について

$$p(x)S(\log \frac{p(x)}{q(x)}) = 0.$$

$p = 0$ ではないので殆ど全ての x について

$$S(\log \frac{p(x)}{q(x)}) = 0.$$

$S(x) = 0$ となる x は 0 のときだけだから, 殆ど全ての x について $p(x) = q(x)$.

真のモデル $p(D|M)$ があったときに, モデルエビデンス $p(D|M')$ とのカルバック距離 $\text{KL}(p(D|M)||p(D|M'))$ は 0 に近いほど真のモデルに近そうだということにする.