

# PRML の 4 章のための数学

サイボウズ・ラボ 光成滋生

2011 年 5 月 13 日

## 1 概要

この文章は『パターン認識と機械学習』(以下 PRML) の 4 章を理解するために必要な数学の一部です。間違い、質問などございましたら [herumi@nifty.com](mailto:herumi@nifty.com) または [twitterID:herumi](https://twitter.com/herumi) までご連絡ください。

## 2 行列の微分の復習

$A = (a_{ij})$  とかいた。

$$(AB)_{ij} = \sum_k a_{ik} b_{kj}.$$

$$\text{tr}(A) = \sum_i a_{ii}$$

$$A^T = (a_{ji})$$

などを思い出しておく。

さて  $A, B$  を適当な行列として

$$\frac{\partial}{\partial A} \text{tr}(AB) = B^T$$

なぜなら,

$$\left( \frac{\partial}{\partial A} \text{tr}(AB) \right)_{ij} = \frac{\partial}{\partial a_{ij}} \sum_{s,t} a_{st} b_{ts} = b_{ji}.$$

ここで  $\frac{\partial}{\partial a_{ij}} a_{st} = \delta_{is} \delta_{jt}$  を使った。つまり添え字  $s, t$  が走るときに,  $s = i, t = j$  のときのみが生き残るというわけである。

慣れるためにもう一つやっておこう。

$$\frac{\partial}{\partial A} \text{tr}(ABA^T) = A(B + B^T).$$

なぜなら,

$$\begin{aligned}
\frac{\partial}{\partial a_{ij}} \text{tr}(ABA^T) &= \frac{\partial}{\partial a_{ij}} \sum_{s,t,u} a_{st} b_{tu} a_{su} \\
&= \sum_{s,t,u} b_{tu} \frac{\partial}{\partial a_{ij}} (a_{st} a_{su}) \\
&= \sum_{s,t,u} b_{tu} (\delta_{is} \delta_{jt} a_{su} + a_{st} \delta_{is} \delta_{ju}) \\
&= \sum_u b_{ju} a_{iu} + \sum_t b_{tj} a_{it} \\
&= \sum_u a_{iu} b_{ju} + \sum_t a_{it} b_{tj} \\
&= (AB^T)_{ij} + (AB)_{ij} \\
&= (A(B + B^T))_{ij}.
\end{aligned}$$

### 3 クラス

$K$  個の線形関数を使った  $K$  クラス識別を考える.

$$y_k(x) = w_k^T x + w_{k0}.$$

ここで  $w_k$  は重みベクトル,  $w_{k0}$  はバイアスパラメータでスカラー,  $x$  が分類したい入力パラメータでベクトルである.

クラス分類を次の方法で定義する:  $x$  に対して, ある  $k$  が存在し, 全ての  $j \neq k$  にたいして  $y_k(x) > y_j(x)$  であるとき  $x$  はクラス  $C_k$  に割り当てるとする.

これは well-defined である. つまり

- (一意性)  $x$  が二つの異なるクラス  $C_k$  に  $C'_k$  に属することはない. なぜならそういう  $k, k'$  があったとすると  $y_k(x) > y'_k(x) > y_k(x)$  となり矛盾するから.
- (存在性)  $x$  が与えられたとき  $\{y_k(x)\}$  の最大値  $m$  を与える  $k_0$  がその候補である. もしも  $m = y_{k_0}(x)$  となる  $k$  が複数個存在 ( $k_1, k_2$ ) したとすると, クラス分類はできないが, そういう  $x$  の集合は  $\{x | y_{k_1}(x) = y_{k_2}(x)\}$  の部分集合となり, 通常次元が落ちる. つまり無理できるくらいしかない.

上記で分類されたクラス  $C_k$  に属する空間は凸領域となる. すなわち  $x, x'$  を  $C_K$  の点とすると, 任意の  $\lambda \in [0, 1]$  に対して  $x'' = \lambda x + (1 - \lambda)x'$  も  $C_k$  に属する.

なぜなら  $x, x' \in C_k$  より任意の  $j \neq k$  にたいして  $y_k(x) > y_j(x), y_k(x') > y_j(x')$ .  $y_k(x)$  は  $x$  について線形なので  $\lambda \geq 0, 1 - \lambda \geq 0$  より

$$y_k(x'') = \lambda y_k(x) + (1 - \lambda) y_k(x') > \lambda y_j(x) + (1 - \lambda) y_j(x') = y_j(x'')$$

が成り立つからである.

凸領域は単連結 (simply connected) である. つまりその領域の中に空洞は無い. 任意の凸領域の 2 点を結ぶ線分が凸領域に入ることから直感的には明らかであろう.

## 4 分類における最小二乗

前節では重みベクトル  $w_{k0}$  を別扱いしたが,  $\tilde{w}_k = (w_{k0}, w_k^T)^T$ ,  $\tilde{x} = (1, x^T)^T$  と 1 次元増やすと  $y_k(x) = \tilde{w}^T \tilde{x}$  とかける. 面倒なので  $\tilde{x}$  を  $x$  と置き換えてしまおう.

さらにまとめて  $y(x) = W^T x$  としよう.  $x, y$  はベクトル,  $W$  は行列である.

二乗誤差関数

$$E_D(W) = \frac{1}{2} \text{tr}((XW - T)^T(XW - T))$$

を最小化する  $W$  を求めよう.

$$\begin{aligned} \frac{\partial}{\partial w_{ij}} E_D(W) &= \frac{1}{2} \frac{\partial}{\partial w_{ij}} \sum_{s,t} ((XW - T)_{st})^2 \\ &= \sum_{s,t} (XW - T)_{st} \frac{\partial}{\partial w_{ij}} (XW - T)_{st} \\ &= \sum_{s,t} (XW - T)_{st} \frac{\partial}{\partial w_{ij}} \left( \sum_u x_{su} w_{ut} \right) \\ &= \sum_{s,t,u} (XW - T)_{st} x_{su} \delta_{iu} \delta_{jt} \\ &= \sum_s (XW - T)_{sj} x_{si} \\ &= \sum_s (X^T)_{is} (XW - T)_{sj} \\ &= (X^T (XW - T))_{ij}. \end{aligned}$$

よって

$$\frac{\partial}{\partial W} E_D(W) = X^T (XW - T).$$

$= 0$  において  $X^T XW = X^T T$  より

$$W = (X^T X)^{-1} X^T T.$$