PRML の 9 章の数式の補足

サイボウズ・ラボ 光成滋生

2011 年 7 月 22 日

1 概要

この文章は『パターン認識と機械学習』（以下 PRML）の 9 章の式変形を一部埋めたものです．間違い, 質問などございましたら herumi@nifty.com または twitterID:herumi までご連絡ください．面倒なので特に紛らわしいと思わない限り $\boldsymbol{x}$ を x と書いたりします.

2 復習

よく使ういくつかの式を書いておく．どれも今までに既に示したものである.
https://github.com/herumi/prml/raw/master/prml2.pdf,
https://github.com/herumi/prml/raw/master/prml3.pdf を参照.

行列について

$$
\begin{aligned}
&x^{\boldsymbol{T}}Ax = \mathrm{tr}(Axx^{\boldsymbol{T}})\\
&\frac{\partial}{\partial A}\log|A| = (A^{-1})^{\boldsymbol{T}}\\
&\frac{\partial}{\partial x}\log|A| = \mathrm{tr}(A^{-1}\frac{\partial}{\partial x}A)\\
&\frac{\partial}{\partial A}\mathrm{tr}(A^{-1}B) = -(A^{-1}BA^{-1})^{\boldsymbol{T}}
\end{aligned}
$$

3 混合ガウス分布

離散的な潜在変数を用いた混合ガウス分布の定式化．K 次元 2 値確率変数 z を考える（どれか一つの成分のみが 1 であとは 0）．つまり

$$\sum_k z_k = 1.$$

z の種類は K 個である．$0 \le \pi_k \le 1$ という係数を用いて

$$p(z_k = 1) = \pi_k$$

という確率分布を与える.

$$p(z) = \prod_k \pi_k^{z_k}.$$

$$p(x|z_k=1)=\mathcal{N}(x|\mu_k,\Sigma_k)$$

なので

$$P(x|z)=\prod_k \mathcal{N}(x|\mu_k,\Sigma_k)^{z_k}.$$

これらを合わせて

$$\begin{aligned}
p(x) &= \sum_z p(z)p(x|z) \\
&= \sum_z \prod_k (\pi_k \mathcal{N}(x|\mu_k,\Sigma_k))^{z_k} \\
&\quad z_k \text{ はどれか一つのみが } 1\text{（そのとき } \pi_k\text{）であとは } 0 \text{ なので} \\
&= \sum_k \pi_k \mathcal{N}(x|\mu_k,\Sigma_k).
\end{aligned}$$

x が与えられたときの z の条件付き確率 $p(z_k=1|x)$ を $\gamma(z_k)$ とする.

$$\gamma(z_k)=\frac{p(z_k=1)p(x|z_k=1)}{\sum_j p(z_j=1)p(x|z_j=1)}=\frac{\pi_k\mathcal{N}(x|\mu_k,\Sigma_k)}{\sum_j \pi_j \mathcal{N}(x|\mu_j,\Sigma_j)}.$$

これを混合要素 k が観測値 x に対する負担率という.

4 混合ガウス分布の EM アルゴリズム

混合ガウス分布において観測したデータ集合を $X^{\boldsymbol{T}}=\{x_1,\ldots,x_N\}$, 対応する潜在変数を $Z^{\boldsymbol{T}}=\{z_1,\ldots,z_N\}$ とする. X は $N\times D$ 行列で Z は $N\times K$ 行列.

対数尤度関数の最大点の条件をもとめる.

$$F=\log p(X|\boldsymbol{\pi},\mu,\Sigma)=\sum_{n=1}^N \log(\sum_{j=1}^K \pi_j\mathcal{N}(x_n|\mu_j,\Sigma_j))$$

とする.

$$\frac{\partial}{\partial\mu}\log\mathcal{N}(x|\mu,\Sigma)=\frac{\partial}{\partial\mu}(-\frac{1}{2}(x-\mu)^{\boldsymbol{T}}\Sigma^{-1}(x-\mu))=\Sigma^{-1}(x-\mu)$$

を使うと

$$\begin{aligned}
\frac{\partial}{\partial\mu_k}F &= \sum_n \frac{\pi_k\mathcal{N}(x_n|\mu_k,\Sigma_k)}{\sum_j \pi_j\mathcal{N}(x_n|\mu_j,\Sigma_j)}\Sigma_k^{-1}(x_n-\mu_k) \\
&= \Sigma_k^{-1}(\sum_n \gamma(z_{nk})(x_n-\mu_k))=0.
\end{aligned}$$

よって

$$\sum_n \gamma(z_{nk})x_n-(\sum_n \gamma(z_{nk}))\mu_k=0.$$

$$N_k=\sum_n \gamma(z_{nk})$$

とおくと

$$\mu_k=\frac{1}{N_k}\sum_n \gamma(z_{nk})x_n.$$

これは μ_k が X の重みつき平均であることを示している.

次に Σ_k に関する微分を考える.

$$\mathcal{N} = \mathcal{N}(x|\mu, \Sigma)$$

のとき

$$\log \mathcal{N} = -\frac{D}{2}\log(2\pi) - \frac{1}{2}\log|\Sigma| - \frac{1}{2}\operatorname{tr}(\Sigma^{-1}(x-\mu)(x-\mu)^{\boldsymbol{T}})$$

なので $\Sigma^{\boldsymbol{T}} = \Sigma$ ならば

$$\frac{\partial}{\partial \Sigma}(\log \mathcal{N}) = -\frac{1}{2}(\Sigma^{-1}) + \frac{1}{2}(\Sigma^{-1}(x-\mu)(x-\mu)^{\boldsymbol{T}}\Sigma^{-1}).$$

よって

$$\begin{aligned}\frac{\partial}{\partial \Sigma_k}F &= \sum_n \gamma(z_{nk})\frac{\partial}{\partial \Sigma_k}\mathcal{N}(x_n|\mu_k, \Sigma_k)\\ &= \sum_n \gamma(z_{nk})(-\frac{1}{2}(\Sigma_k^{-1}) + \frac{1}{2}(\Sigma_k^{-1}(x_n-\mu_k)(x_n-\mu_k)^{\boldsymbol{T}}\Sigma_k^{-1})) = 0.\end{aligned}$$

よって

$$\sum_n \gamma(z_{nk})(I - (x_n-\mu_k)(x_n-\mu_k)^{\boldsymbol{T}}\Sigma_k^{-1}) = 0.$$

$$\Sigma_k = \frac{1}{N_k}\sum_n \gamma(z_{nk})(x_n-\mu_k)(x_n-\mu_k)^{\boldsymbol{T}}.$$

最後に π_k に関する微分を考える. $\sum_k \pi_k = 1$ の制約を入れる.

$$G = F + \lambda(\sum_k \pi_k - 1)$$

とすると

$$\frac{\partial}{\partial \pi_k}F = \sum_n \frac{\mathcal{N}(x_n|\mu_k, \Sigma_k)}{\sum_j \pi_j \mathcal{N}(x_n|\mu_j, \Sigma_j)} + \lambda = 0.$$

$\mathcal{N}_{nk} = \mathcal{N}(x_n|\mu_k, \Sigma_k)$ とおくと

$$N = \sum_k N_k = \sum_{n,k}\gamma(z_{nk}) = \sum_k \pi_k(\sum_n \frac{\mathcal{N}_{nk}}{\sum_j \pi_j \mathcal{N}_{nj}}) = -\sum_k \pi_k \lambda = -\lambda.$$

よって

$$\sum_n \frac{\pi_k \mathcal{N}_{nk}}{\sum_j \pi_j \mathcal{N}_{nj}} = \pi_k N.$$

$$\pi_k = \frac{1}{N}\sum_n \gamma(z_{nk}) = \frac{N_k}{N}.$$

5 K-means との関連

式 (9.43) は不正確. E ではなく ϵE を考えないと (9.43) の右辺にはならない. 式 (9.40) を E とおく.

$$E = \sum_{n,k} \gamma(z_{nk})(\log \pi_k + \log \mathcal{N}(x_n|\mu_k, \Sigma_k)).$$

ϵE に

$$\mathcal{N}(x|\mu_k, \Sigma_k) = \frac{1}{(2\pi\epsilon)^{D/2}} \exp(-\frac{1}{2\epsilon}||x - \mu_k||^2)$$

を代入する.

$$\epsilon E = \sum_{n,k} \gamma(z_{nk})(\epsilon \log \pi_k - \frac{D}{2}\epsilon \log(2\pi\epsilon) - \frac{1}{2}||x_n - \mu_k||^2).$$

$\epsilon \to 0$ で

$$\gamma(z_{nk}) \to r_{nk}.$$

$$\epsilon \log \pi_k \to 0.$$

$$\epsilon \log(2\pi\epsilon) \to 0$$

より

$$\epsilon E \to -\frac{1}{2} \sum_{n,k} r_{nk} ||x_n - \mu_k||^2 = -J.$$

よって期待完全データ対数尤度の最大化は J の最小化と同等.